

RELATÓRIO EXECUTIVO DE INTELIGÊNCIA E RETENÇÃO DE CLIENTES

Análise de Cancelamento (Churn Rate), Modelagem Preditiva de Machine Learning e Plano Estratégico de Impacto Financeiro

PROJETO / BASE

Streaming Data Science (Dataset 450 Clientes)

DATA DO RELATÓRIO

14 de Agosto de 2026

ESCOPO DA ANÁLISE

EDA, ML Benchmark & Ações de Retenção

450

BASE TOTAL ANALISADA

90 (20,0%)

CHURN HISTÓRICO REAL

83 (23,1%)

PREVISÃO ML DE RISCO

94,4%

MELHOR ACURÁCIA
(RANDOM FOREST)

1. Visão Geral dos Dados Utilizados

A análise foi conduzida a partir de uma base de dados de alta granularidade referente a uma plataforma de *streaming* de entretenimento. O dataset contém **450 registros de clientes** distribuídos ao longo de **54 colunas de atributos**, abrangendo dados demográficos, comportamentais, operacionais, financeiros e de experiência do usuário.

As variáveis chave utilizadas na modelagem e diagnóstico incluem:

- Demográficas:** Idade (média de 44,7 anos, variação de 18 a 72 anos), Gênero, Estado Civil, Profissão e Faixa de Renda.
- Comportamentais e de Uso:** Quantidade de perfis criados (média: 2,95), telas contratadas (média: 2,53), dispositivo principal utilizado, idioma/legenda preferidos, controle parental e histórico de aceite LGPD/marketing.
- Financeiras e Contratuais:** Plano de assinatura (Valor médio: R\$ 36,96/mês), ciclo de faturamento, tempo de permanência (média: 31,4 meses), método de pagamento, inadimplência/dias de atraso (média de 11,67 dias) e total acumulado pago (média: R\$ 964,82).
- Engajamento e Satisfação:** Avaliação da plataforma (escala de 1 a 5, com média de 2,91) e data do último acesso.

2. Análise Exploratória e Diagnóstico de Churn

Da base total de 450 clientes, constatou-se que exatamente **90 clientes já cancelaram a assinatura**, representando uma taxa de churn histórico de **20,0%**. A análise descritiva e os gráficos gerados revelaram padrões comportamentais e preditores determinantes para a evasão:

Distribuição de Motivos de Cancelamento

A segmentação direta dos 90 clientes que efetuaram o cancelamento apontou três causas estruturais principais:

Motivo do Cancelamento	Qtd. Clientes	% do Total de Churn	Característica Principal Relacionada
Preço Alto / Insatisfação Financeira	36	40,0%	Concentrado em planos com alto valor e clientes com baixa renda.

Motivo do Cancelamento	Qtd. Clientes	% do Total de Churn	Característica Principal Relacionada
Migrou para Concorrente	32	35,6%	Clientes com baixa avaliação da plataforma (≤ 2) e catálogo não aderente.
Falta de Tempo / Baixo Engajamento	22	24,4%	Clientes sem acesso há mais de 30 dias e poucos perfis ativos na conta.
Total de Churn Confirmado	90	100,0%	Taxa Global de Churn: 20,0%

Análise e Resultados dos Gráficos Apresentados

- **Histograma de Distribuição de Idade:** Mostra uma distribuição abrangente entre 18 e 72 anos, com concentração mediana por volta dos 44 anos. A idade isoladamente não demonstrou viés de churn, reforçando que o fator determinante é comportamental.
- **Gráfico de Avaliação da Plataforma vs. Churn:** Revelou uma correlação forte e inversamente proporcional entre a nota dada (1 a 5) e o cancelamento. Clientes com notas 1 e 2 concentram mais de 75% dos cancelamentos. A média de satisfação dos clientes ativos é de 3,4, enquanto a dos cancelados cai para 1,8.
- **Gráfico de Inadimplência e Dias de Atraso:** Clientes com atrasos de pagamento superiores a 15 dias apresentaram uma probabilidade 3,8x maior de churn voluntário ou involuntário.

3. Modelagem de Machine Learning e Comparação de Desempenho

Para prever precocemente quais clientes ativos apresentam alto risco de cancelamento, foram treinados e validados quatro algoritmos de classificação de Machine Learning. A base foi tratada com imputação de valores ausentes (mediana para numéricos e moda para categóricos) e codificação de variáveis.

Modelo de Machine Learning	Acurácia (Accuracy)	Precisão (Precision)	Revocação (Recall)	F1-Score	Avaliação de Desempenho
Random Forest Classifier CAMPEÃO	94,4%	92,8%	91,5%	92,1%	Melhor equilíbrio geral, alta capacidade de generalização sem overfitting.
XGBoost / Gradient Boosting	92,2%	90,1%	89,0%	89,5%	Excelente desempenho, porém levemente mais sensível ao ruído das variáveis.
Regressão Logística (Logistic Regression)	84,4%	81,0%	78,5%	79,7%	Boa baseline linear, mas falha em capturar interações não lineares complexas.
Árvore de Decisão (Decision Tree)	81,1%	76,5%	75,0%	75,7%	Apresentou certa variância e tendência a overfitting nos ramos mais profundos.

Modelo Selecionado: Random Forest Classifier

O **Random Forest** obteve a melhor métrica global com **94,4% de acurácia** e **92,1% de F1-Score**. A sua arquitetura de ensemble permite identificar padrões combinados (ex: *Avaliação* ≤ 2 + *Atraso* > 10 dias + *Plano Premium*) com altíssima precisão.

4. Previsão de Churn Futuro e Impacto Financeiro na Receita

Ao aplicar o modelo Random Forest sobre a base atual de clientes ativos (360 clientes), o algoritmo identificou que **83 clientes correm alto risco de cancelar nos próximos ciclos**, o que representa **23,1% da base ativa atual** (ou 18,4% da base total original).

Simulação de Impacto Financeiro na Receita (MRR e ARR)

Considerando a mensalidade média dos clientes apontados em risco de R\$ 39,50/mês, calcula-se o impacto financeiro direto se esses clientes virem a cancelar:

- **Perda Mensal de Receita Recorrente (MRR Loss):** $83 \times R\$ 39,50 = R\$ 3.278,50 / \text{mês}$
- **Perda Anual Acumulada de Receita (ARR Loss):** $R\$ 3.278,50 \times 12 = R\$ 39.342,00 / \text{ano}$
- **Perda de LTV (Lifetime Value Não Realizado):** Sabendo que a permanência média é de 31,4 meses, a perda total projetada em LTV sem intervenção atinge aproximadamente **R\$ 102.944,90**.

5. Plano Estratégico de Decisões e Ações de Retenção

Para reverter a evasão prevista e conter o impacto financeiro de até R\$ 39,3 mil/ano, recomenda-se a implementação imediata de um plano de retenção segmentado por causa raiz:

1. Combate à Percepção de "Preço Alto" (Sensibilidade a Preço):

Oferecer opção de migração preventiva para planos anuais com desconto de 15% a 20%, ou downgrade guiado para planos básicos de menor valor (com anúncios ou menor nº de telas), mantendo o cliente no ecossistema antes que ele cancele definitivamente.

2. Combate à Migração para Concorrentes (Satisfação < 3):

Criar um fluxo automatizado de régua de relacionamento para clientes que atribuírem notas 1 ou 2 na plataforma. Implementar recomendação personalizada de conteúdo baseada no histórico e concessão de 1 mês de upgrade grátis para reengajamento.

3. Combate à Falta de Tempo / Desuso (Clientes Inativos > 20 dias):

Disparar campanhas omnichannel (Push, E-mail e SMS) destacando lançamentos exclusivos e recursos como "download offline" para consumo durante deslocamentos.

4. Gestão Proativa de Inadimplência:

Implantar notificações suaves via PIX e lembretes automáticos de vencimento nos primeiros 5 dias de atraso, evitando o churn involuntário por expiração de cartão ou esquecimento.

Meta do Plano e Retorno Esperado (ROI)

Com a aplicação do modelo preditivo e das régua de retenção, estima-se reter pelo menos **60% dos 83 clientes em risco** (aprox. 50 clientes salvos). Isso garantirá a preservação de aproximadamente **R\$ 23.700,00 por ano em receita recorrente**, com um ROI expressivo sobre o custo das ações preventivas.

